


Power BI

урок 2

Екатерина Рехерт

DataBoom.kz

Спасибо за обратную связь!



План

- PowerQuery и ETL
- Практика


Power BI Desktop 80%

20%



Query Editor

Power Query



*Model
Relationships + DAX*


Data Model + DAX



Visualizations


Visuals + UI/UX






Кухня
= Power Query Editor
= Редактор Запросов

Что такое ETL?






EXTRACT




TRANSFORM



LOAD

Power Query Editor нужен для ETL



Power Query - интерфейс, генерирующий код на языке M

Power Query is just a UI that generates M




М QUERY ИЛИ ПРОСТО
М

M QUERY OR SIMPLY M



М ОТ СЛОВА “MASH-UP” —
ПЮРЕ

M IS FOR “MASH-UP”



ЖМИ на ADVANCED EDITOR,
включи “formula bar” чтобы
увидеть М

go to “Advanced Editor”,
TURN ON “Formula bar” to see M

EXTRACT – запрашиваем (query) данные из ИСТОЧНИКОВ данных




Источники, которые мы пройдем с вами на этой неделе:

- Excel
- CSV
- папка с файлами
- Google Sheets
- Web
- PDF
- ручной ввод данных
- SQL база данных

Что такое База Данных?





Что такое База Данных (DataBase)?

- База данных — организованная структура для хранения и обработки данных
- A database is an organized collection of data for storage and retrieval

Какие типы Баз Данных вы знаете?



Типы баз данных

Flat file

plain text file data storage
данные хранятся в текстовом
виде в “плоском” файле,
например: CSV, TXT

Flat file

plain text file data storage
данные хранятся в текстовом виде
в “плоском” файле : CSV, TXT

- **двумерные, как и таблицы (2 dimensional, like tables)**
- **редко используются для хранения данных, но часто - для выгрузки и обмена**
- **многие системы (БД, CRM, ERP) имеют возможность выгрузки и загрузки данных в/их Flat File**

22pbi_accounts - Notepad

File Edit Format View Help

```
pbi01,databoom123,Ramadinkyzy,Kymbat
pbi02,databoom123,Aigarayev,Amangeldy
pbi03,databoom123,Utepova,Dinara
pbi04,databoom123,Baidalinova,Zhansaule
pbi05,databoom123,Atymtayeva,Shynar
pbi06,databoom123,Sakiyeva,Guldana
pbi07,databoom123,Kulikova,Yuliya
pbi08,databoom123,Saukambekov,Olzhas
pbi09,databoom123,ZHAMIL,DARYN
pbi10,databoom123,Razmatova,Madina
pbi11,databoom123,Tsoy,Olga
pbi12,databoom123,GUSHTYK,ANNA
pbi13,databoom123,Kassimova,Indira
pbi14,databoom123,Joldassova,Bagila
pbi15,databoom123,Omarova,Bota
pbi16,databoom123,Pompushko,Yuriy
pbi17,databoom123,Zhunisbayeva,Aigerim
pbi18,databoom123,Amirova,Zarina
pbi19,databoom123,Baryshev,Roman
pbi20,databoom123,Mussabekova,Aina
pbi21,databoom123,Rangno,Stanislav
pbi22,databoom123,Babkin,Mikhail
pbi23,databoom123,Кучкарова,Насиба
pbi24,databoom123,Polyakova,Natalya
pbi25,databoom123,Shuvakov,Anton
pbi26,databoom123,Vavilin,Yuriy
pbi27,databoom123,Yessegazyeva,Aigerim
pbi28,databoom123,Galikhanov,Dinnur
pbi29,databoom123,Tashmetov,Komilzhon
pbi30,databoom123,Yelamanova,Akku
```

**ЧТО
ОЗНАЧАЕТ
ФОРМАТ
CSV? TXT?**



Типы баз данных

Flat file

plain text file data storage
данные хранятся в текстовом
виде в “плоском” файле,
например: CSV, TXT


Hierarchical

структура «Дерево», каждый
«родитель» может иметь много
«детей», но у каждого «ребенка»
только один «родитель»


Hierarchical

структура «Дерево», каждый «родитель» может иметь много «детей», но у каждого «ребенка» только один «родитель»

- были популярны до того, как появились реляционные (relational), сейчас уже не используются
- Parent-Child relationships (Дерево)



Hierarchical database model



Типы баз данных

Flat file

plain text file data storage
данные хранятся в текстовом
виде в “плоском” файле,
например: CSV, TXT

Hierarchical

структура «Дерево», каждый
«родитель» может иметь много
«детей», но у каждого «ребенка»
только один «родитель»

Relational (SQL)


структурированное табличное
хранение данных

highly-structured tabular data
storage

Relational (SQL)

структурированное табличное хранение данных

- появилась в 1970х годах и популярна с тех пор
- Таблицы и связи между ними
- scalability issues: не всегда удобно/выгодно увеличивать память или новые серверы заводить



Что такое SQL



Что такое **SQL**?

STRUCTURED
QUERY
LANGUAGE

Эскуэль
ЭсКьюЭль
СиКуЭль
СиКьюЭль
Сиквэл
Сиквел



Nota Bene: PowerBI vs SQL



Power Query Editor
M Query Language

SQL


STRUCTURED
QUERY
LANGUAGE

М и SQL это языки программирования?




SQL –

структурированный
язык запросов
для взаимодействия
с реляционными
базами данных



М — язык запросов для взаимодействия с
множеством источников данных



80% вакансий в сфере анализа данных требуют знаний SQL. А также, SQL нужен любому программисту

Несколько примеров:

- Data Analyst
- Data Scientist
- Data Engineer
- Database Administrator
- Backend Developer
- Frontend Developer
- QA tester

По данным
исследования*
Kolesa Zerttey
—73% компаний
используют SQL-
решения для
хранения данных

*Ссылка на исследование
https://job.kolesa.kz/dl/Data_Science_Analytics.pdf

Системы хранения данных

Интересно, что о DWH говорят около половины респондентов, но при этом около 48 % хранят данные в Excel и других spreadsheet — таблицах. Возможно, это связано с тем, что во многих компаниях большая часть данных все-таки представлена в формате small-data.



Типы баз данных

Flat file

plain text file data storage
данные хранятся в текстовом
виде в “плоском” файле,
например: CSV, TXT

Hierarchical

структура «Дерево», каждый
«родитель» может иметь много
«детей», но у каждого «ребенка»
только один «родитель»

Relational (SQL)

структурированное табличное
хранение данных

highly-structured tabular data
storage

Non-Relational (NoSQL)


Нетабличный вид хранения данных

non-tabular data storage

Non-Relational (NoSQL)

Нетабличный вид хранения данных

- нереляционные
- используются тогда, когда реляционные уже не вмещают (scalability issues, extremely large amounts of data)
- данные хранятся НЕ в таблицах



Типы баз данных

Flat file

plain text file data storage
данные хранятся в текстовом
виде в “плоском” файле,
например: CSV, TXT

Hierarchical

структура «Дерево», каждый
«родитель» может иметь много
«детей», но у каждого «ребенка»
только один «родитель»

Relational

структурированное табличное
хранение данных


highly-structured tabular data
storage

Non-Relational



Нетабличный вид хранения данных

non-tabular data storage

Что мы делаем на «кухне» Power Query?







ETL: TRANSFORM



дверь на кухню

инструменты на кухне



The background of the image features a close-up, high-contrast photograph of several interlocking metal gears. The gears are dark, possibly black or dark grey, with a visible metallic texture. The lighting creates strong highlights on the edges of the teeth and deep shadows in the gaps between them, giving a sense of depth and mechanical complexity. The composition is slightly off-center, with the gears filling the entire frame.

HUMAN FRIENDLY vs. MACHINE FRIENDLY

HUMAN FRIENDLY vs. MACHINE FRIENDLY

- в одном столбце только один вид данных
- удаляем «лишние» строки, столбцы
- отключаем Enable Load (загрузку в модель данных) у тех таблиц, которые являются не финальными, а лишь составляющими «кусочками»

Что такое НОРМАЛИЗАЦИЯ ДАННЫХ?



The Relational Data Model

- данные хранятся в множестве связанных между собой таблиц – таблицы и связи между ними
- Святой Грааль - Третья Форма Нормальности, данные приведены в такой вид, когда целостность данных наивысшая, а различные аномалии, неполные и лишние данные отсутствуют

The holy grail of DB design is getting your DB into 3NF 3rd normal form – highest in terms of data integrity, reduced anomalies like redundancy and incomplete data

NORMALIZATION - НОРМАЛИЗАЦИЯ

Зачем нужна нормализация данных?



BENEFITS OF NORMALIZATION

- Целостные данных и отсутствие «лишних» данных (improved data integrity, no redundant data)
- Меньший размер и лучше производительность (smaller databases - better performance)
- Меньше индексов, меньше менеджмента (fewer indexes, less management)
- Предупреждает аномалии в обновлении/изменении данных (prevents data modification anomalies)

**Сколько
существует форм
нормальности
(normal forms)?**



Normal Forms

```
graph TD; NF[Normal Forms] --- 1NF[1NF]; NF --- 2NF[2NF]; NF --- 3NF[3NF]; NF --- BCNF[BCNF]; NF --- 4NF[4NF]; NF --- 5NF[5NF];
```

1NF

2NF

3NF

BCNF

4NF

5NF

First Normal Form(1NF)

1NF

- В каждой колонке только один вид данных
- Каждая строка имеет уникальный идентификатор

Second Normal Form(2NF)

2NF

- Удовлетворены условия 1 формы нормальности
- Частичные зависимости удалены

Third Normal Form(3NF)

- Удовлетворены условия 2 формы нормальности
- отсутствуют транзитивные функциональные зависимости неключевых атрибутов от ключевых

1st Normal Form

- Удаляем повторяющиеся группы колонок, делаем так, чтобы в одной колонке был только один вид данных и одно значение, создаем/проверяем наличие уникального идентификатора каждой строки - PRIMARY KEY (PK)

(ELIMINATE REPEATING GROUPS OF DATA OR REPEATING COLUMNS + PRIMARY KEY)

1	NAME	DOB	CERTIFICATIONS	CERTIFICATION 1	CERTIFICATION 2	CERTIFICATION 3
2	Yekaterina	8/12/1993	MVP, MTA: Databases & SQL, PowerBI	PowerBI	MTA: Databases & SQL	MVP
3	Aigerim	3/1/1992	PowerBI	PowerBI	NULL	NULL
4	Meruert	10/28/1992	PowerBI, Excel, MSCA	PowerBI	Excel	MSCA
5	Aleksandra	7/15/1996	PowerBI	PowerBI	NULL	NULL

1st Normal Form

1	NAME	DOB	CERTIFICATIONS	CERTIFICATION 1	CERTIFICATION 2	CERTIFICATION 3
2	Yekaterina	8/12/1993	MVP, MTA: Databases & SQL, PowerBI	PowerBI	MTA: Databases & SQL	MVP
3	Aigerim	3/1/1992	PowerBI	PowerBI	NULL	NULL
4	Meruert	10/28/1992	PowerBI, Excel, MSCA	PowerBI	Excel	MSCA
5	Aleksandra	7/15/1996	PowerBI	PowerBI	NULL	NULL



LearnerID	LearnerName	DOB	CertificationID	CertificationName	VendorName	DateAcquired
1	Yekaterina	8/12/1993	1	MTA: Databases & SQL	Microsoft	9/12/2017
1	Yekaterina	8/12/1993	2	PowerBI	Microsoft	11/12/2019
1	Yekaterina	8/12/1993	3	Most Valuable Professional	Microsoft	2/1/2021
2	Aigerim	3/1/1992	2	PowerBI	Microsoft	12/12/2020
3	Meruert	10/28/1992	2	PowerBI	Microsoft	1/12/2021
3	Meruert	10/28/1992	3	Excel	Microsoft	1/15/2021
3	Meruert	10/28/1992	4	MSCA	Microsoft	1/15/2021
4	Aleksandra	7/15/1996	2	PowerBI	Microsoft	1/15/2021

First Normal Form(1NF)

1NF

- В каждой колонке только один вид данных
- Каждая строка имеет уникальный идентификатор

Second Normal Form(2NF)

2NF

- Удовлетворены условия 1 формы нормальности
- Частичные зависимости удалены

Third Normal Form(3NF)

- Удовлетворены условия 2 формы нормальности
- отсутствуют транзитивные функциональные зависимости неключевых атрибутов от ключевых

2nd Normal Form

- 1NF + Частичные зависимости от РК удалены

1NF + NO PARTIAL DEPENDENCIES ON THE PK (in case with composite key).

*Если РК задан одной колонкой, то ничего не нужно делать, таблица УЖЕ в 2NF

2nd Normal Form

- 1NF + Частичные зависимости от РК удалены

LearnerID	LearnerName	DOB
1	Yekaterina	8/12/1993
2	Aigerim	3/1/1992
3	Meruert	10/28/1992
4	Aleksandra	7/15/1996

CertificationID	CertificationName	VendorName
1	MTA: Databases & SQL	Microsoft
2	PowerBI	Microsoft
3	Most Valuable Professional	Microsoft
4	MSCA	Microsoft
5	Excel	Microsoft

LearnerID	CertificationID	DateAcquired
1	1	9/12/2017
1	2	11/12/2019
1	3	2/1/2021
2	2	12/12/2020
3	2	1/12/2021
3	5	1/15/2021
3	4	1/15/2021
4	2	1/15/2021

3rd Normal Form

- 1NF + 2NF + каждая колонка должна зависеть полностью от РК (применимо только к таблицам с ключем состоящим из одного поля)

CertificationID	CertificationName	VendorName
1	MTA: Databases & SQL	Microsoft
2	PowerBI	Microsoft
3	Most Valuable Professional	Microsoft
4	MSCA	Microsoft
5	Excel	Microsoft



CertificationID	CertificationName	VendorID
1	MTA: Databases & SQL	1
2	PowerBI	1
3	Most Valuable Professional	1
4	MSCA	1
5	Excel	1



VendorID	VendorName
1	Microsoft
2	Amazon

First Normal Form(1NF)

1NF

- В каждой колонке только один вид данных
- Каждая строка имеет уникальный идентификатор

Second Normal Form(2NF)

2NF

- Удовлетворены условия 1 формы нормальности
- Частичные зависимости удалены

Third Normal Form(3NF)

- Удовлетворены условия 2 формы нормальности
- отсутствуют транзитивные функциональные зависимости неключевых атрибутов от ключевых

3rd Normal Form

LearnerID	LearnerName	DOB
1	Yekaterina	8/12/1993
2	Aigerim	3/1/1992
3	Meruert	10/28/1992
4	Aleksandra	7/15/1996


LearnerID	CertificationID	DateAcquired
1	1	9/12/2017
1	2	11/12/2019
1	3	2/1/2021
2	2	12/12/2020
3	2	1/12/2021
3	5	1/15/2021
3	4	1/15/2021
4	2	1/15/2021

CertificationID	CertificationName	VendorID
1	MTA: Databases & SQL	1
2	PowerBI	1
3	Most Valuable Professional	1
4	MSCA	1
5	Excel	1


VendorID	VendorName
1	Microsoft
2	Amazon

ETL: TRANSFORM


ДВА ГЛАВНЫХ РЕЦЕПТА НА КУХНЕ



MERGE




APPEND





ETL: TRANSFORM

MERGE



Результат: больше столбцов

APPEND






Результат: больше строк

APPEND – вертикальное склеивание таблиц


- Одинаковое кол-во столбцов
- Одинаковые типы данных
- Одинаковый порядок столбцов
- *Одинаковые названия столбцов*

APPEND




MERGE – горизонтальное склеивание таблиц

- Нужен ключ (общее поле/колонка), похоже на ВПР/VLOOKUP
- Разные виды соединений: левое, правое и др.



MERGE –



Nota Bene: PowerBI vs SQL





SQL

MERGE = JOIN


APPEND = UNION

Визуализация видов JOIN в PowerBI






EXTRACT



TRANSFORM



LOAD



Power BI Desktop практика

